





# Persistência Poliglota:

Fundamentos, Desafios & Oportunidades



**Ronaldo dos Santos Mello** 

GBD/PPGCC/INE/CTC/UFSC



# **Agenda**

- 1. Persistência Poliglota: O que é?!
- 2. SGPD: Arquiteturas de base
- 3. SGPD: Desafios & Oportunidades de Pesquisa

# **Agenda**

### 1. Persistência Poliglota: O que é?!

2. SGPD: Arquiteturas de base

3. SGPD: Desafios & Oportunidades de Pesquisa

#### Motivação

- dados hoje são gerenciados em diferentes contextos/requisitos
  - dados simples X dados complexos
  - dados E x SE x ÑE
  - consistência X escalabilidade
  - batch X tempo real
  - write-intensitve X read-intensive workloads
  - acesso baseado em chave/filtros (OLTP)
     X consultas analíticas (OLAP) . . .

#### Polyglot Data Management: State of the Art & Open Challenges



#### Motivação

- dados hoje são gerenciados em diferentes contextos/requisitos
  - dados simples X dados complexos
  - dados E x SE x ÑE
  - consistência X escalabilidade
  - batch X tempo real
  - write-intensitve X read-intensive workloads
  - acesso baseado em chave/filtros (OLTP)
     X consultas analíticas (OLAP) . . .
- cada contexto/requisito ⇒ 1 ou poucas tecnologias de BD (SGBDs)
  - relacional, OR, XML, chave-valor, grafo, documento, text search engine, array

#### Polyglot Data Management: State of the Art & Open Challenges



- aplicações geralmente utilizam 1 tecnologia de BD
- mas e se a minha aplicação precisa gerenciar dados em múltiplos contextos/requisitos?



- mas e se a minha aplicação precisa lidar com dados em múltiplos contextos/requisitos?
- cenário exemplo: e-commerce
  - registros de produtos
  - descrições textuais de produtos
  - fotos/vídeos de produtos
  - avaliações de produtos



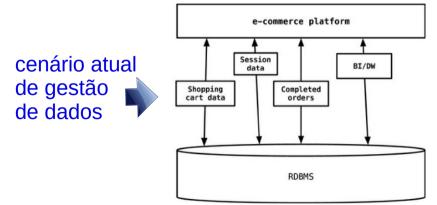
- mas e se a minha aplicação precisa lidar com dados em múltiplos contextos/requisitos?
- cenário exemplo: e-commerce
  - dados com naturezas diferentes:
    - registros de produtos (estruturado simples)
    - descrição textual do produto (não-estruturado)
    - conteúdo do produto (p.ex: livro) (estruturado complexo ou semiestruturado)
    - fotos e vídeos do produto (não-estruturado)
    - rede de recomendação cliente-produto ou produto-produto ou cliente-cliente (estruturado complexo)
    - dados para big data analytics (DW, DL)



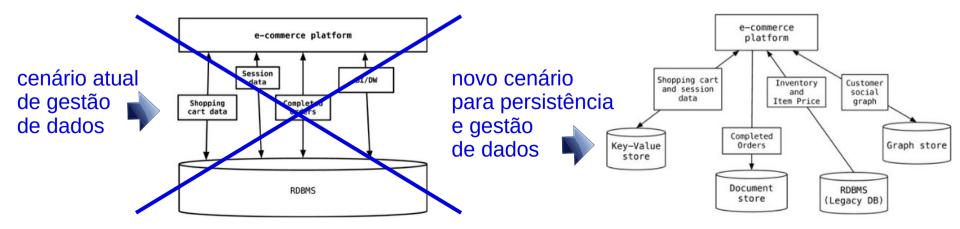
- mas e se a minha aplicação precisa lidar com dados em múltiplos contextos/requisitos?
- cenário exemplo: e-commerce
  - múltiplos requisitos de gerência de dados:
    - acesso a avaliações de produtos (alta disponbilidade; consistência fraca; OLTP-readintensive)
    - acesso a produtos (alta disponbilidade; consistência forte; OLTP-read-intensive)
    - vendas (consistência forte; OLTP-writeintensive)
    - análise de perfis de usuários, vendas e recomendação de produtos (OLAP)



- mas e se a minha aplicação precisa lidar com dados em múltiplos contextos/requisitos?
- cenário exemplo: e-commerce



- mas e se a minha aplicação precisa lidar com dados em múltiplos contextos/requisitos?
- cenário exemplo: e-commerce



#### Persistência Poliglota

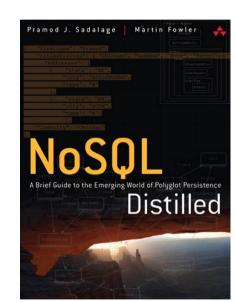
 "Combinar benefícios de diferentes tecnologias de BD evitando seus pontos fracos e deixando transparente a coordenação dessas tecnologias" (Sadalage & Fowler, 2012)

• materializado como um SGPD (sistema de gerência

poliglota de dados)







- SGPD Principais requisitos a considerar
  - **1. Poder de modelagem** (modelos de dados suportados & naturezas de dados suportadas)

- SGPD Principais requisitos a considerar
  - 1. Poder de modelagem (modelos de dados suportados & naturezas de dados suportadas)
  - **2. Expressividade de linguagens/operações de acesso** (capacidades DDL e DML dos modelos de dados: *schema/schemaless*; restrições de integridade; capacidades de consulta: *key-based*, *set-based*, *navigate paths*, operadores não-relacionais p.ex: espaço-temporais, *arrays*, grafos agrupamento/inserção *on demand* de *streams* de dados; 1 ou + interfaces de acesso para esses modelos)

#### SGPD – Principais requisitos a considerar

- 1. Poder de modelagem (modelos de dados suportados & naturezas de dados suportadas)
- 2. Expressividade de linguagens/operações (capacidades DDL e DML dos modelos de dados: schema/schemaless; restrições de integridade; capacidades de consulta: key-based, set-based, navigate paths, operadores não-relacionais p.ex: espaço-temporais, arrays, grafos agrupamento/inserção on demand de streams de dados; 1 ou + interfaces de acesso para esses modelos)
- **3.** Adaptação fácil e transparente a mudanças de contextos/requisitos (acionamento de novas tecnologias de BD com novos modelos devido a mudanças nos requisitos de dados da aplicação; migração/replicação de dados entre modelos de BD devido a mudanças no workload; replanejamento de acesso devido a mudanças no workload; capacidades de adaptação automáticas self-managed SGPD (machine learning??))

# **Agenda**

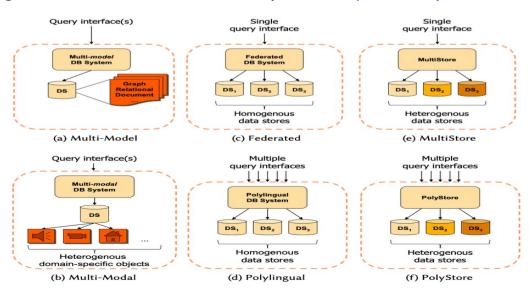
- 1. Projeto Tradicional de um BD
- 2. Persistência Poliglota: O que é?!

### 3. SGPD: Arquiteturas de base

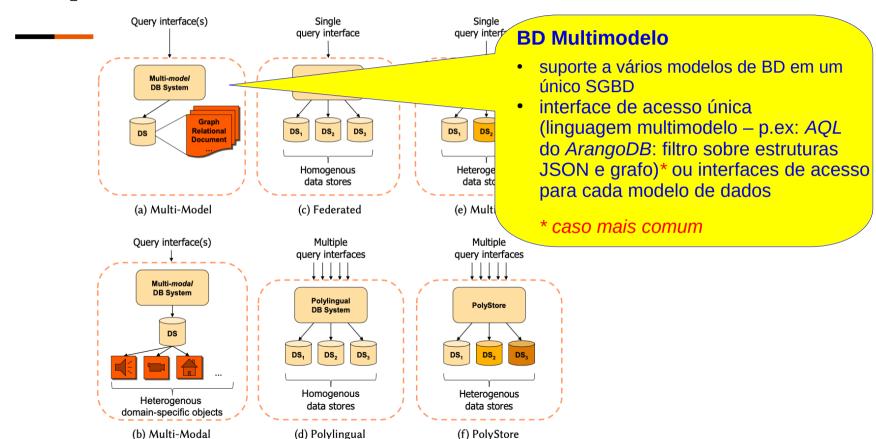
4. SGPD: Desafios & Oportunidades de Pesquisa

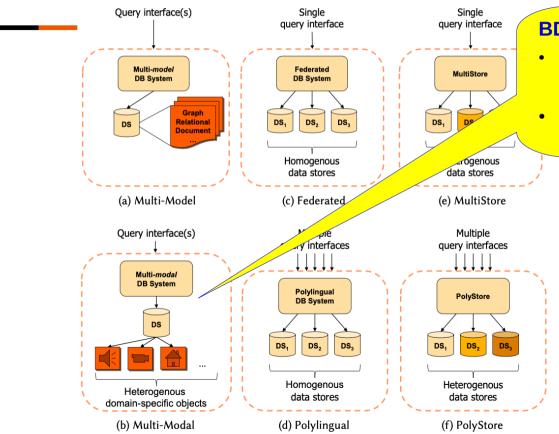
- Diversas abordagens na literatura possuem semelhança com a ideia de um SGPD
  - heterogeneidade em termos de arquitetura (falta de padronização...)

- Diversas abordagens na literatura possuem semelhança com a ideia de um SGPD
  - heterogeneidade em termos de arquitetura (falta de padronização...)



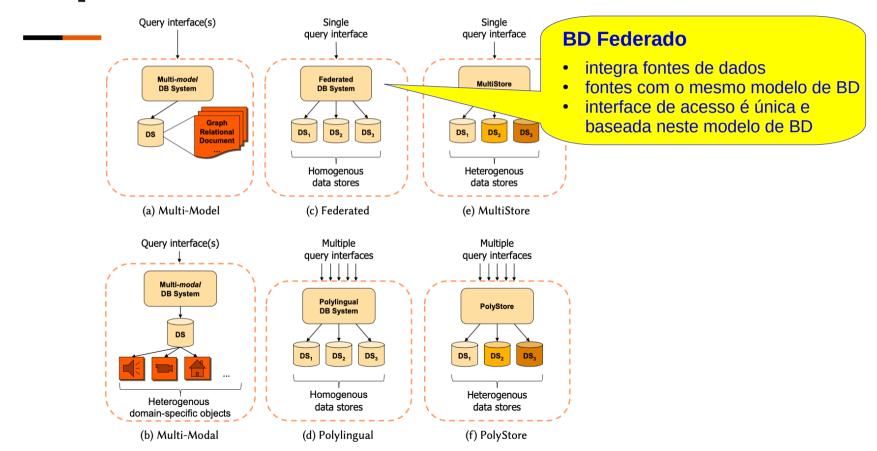


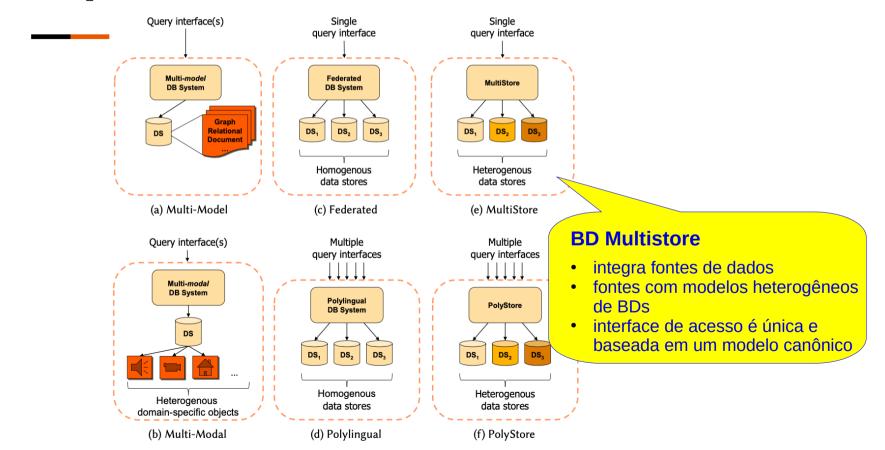


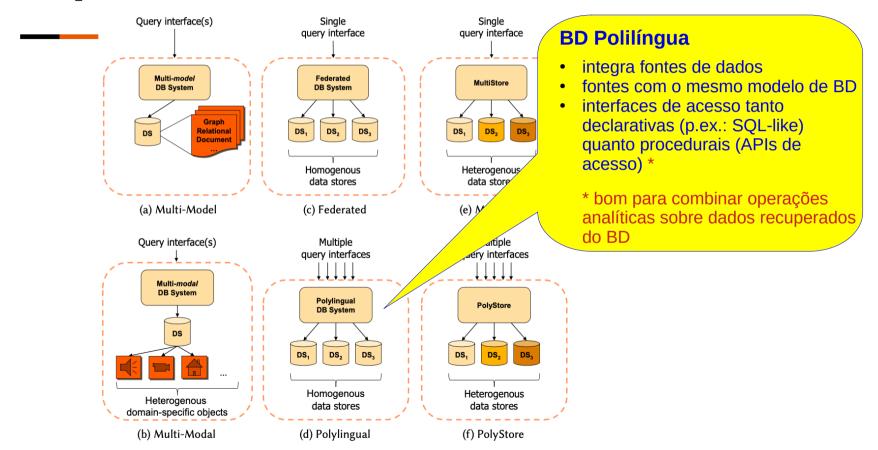


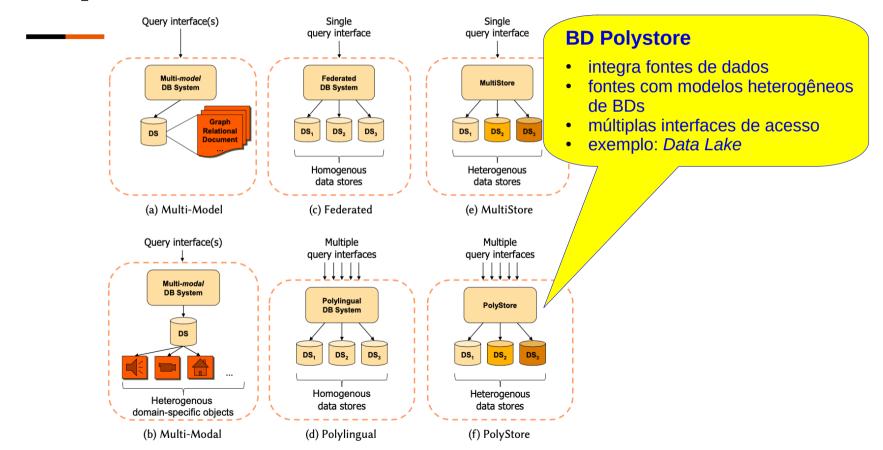
#### **BD Multimodal**

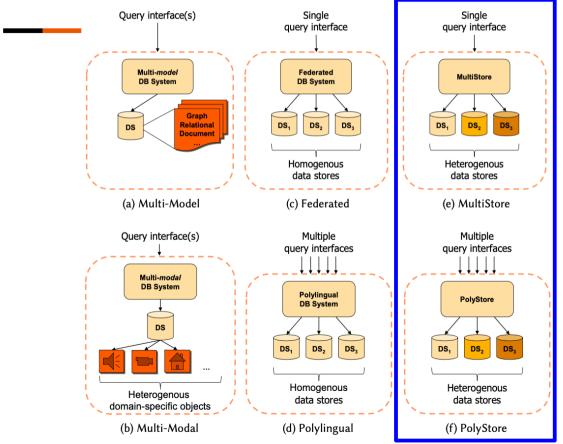
- organiza dados não por modelo de BD, mas por natureza do dado (texto, imagem, vídeo, ...)
- interfaces de acesso específicas por natureza do dado













arquiteturas de base mais consideradas para um SGPD

Qual a diferença entre a arquitetura de um SGPD e...

- Qual a diferença entre entre a arquitetura um SGPD e...
- a arquitetura de um Sistema de Integração de Dados (SID)? Um SID visa acesso integrado a dados geralmente para fins de read, enquanto um SGPD pode ser usado para fins OLTP (read e write) e OLAP (read for analytics)

- Qual a diferença entre a arquitetura de um SGPD e...
- a arquitetura de um SGBD Distribuído (SGBDD)? Um SGBDD geralmente possui uma única interface de acesso para os nodos servidores de dados, enquanto um SGPD pode ter múltiplas interfaces de acesso, além do dinamismo para lidar com múltiplos (e considerar novos) modelos de dados e realizar migração/replicação de dados conforme mudam requisitos e workload

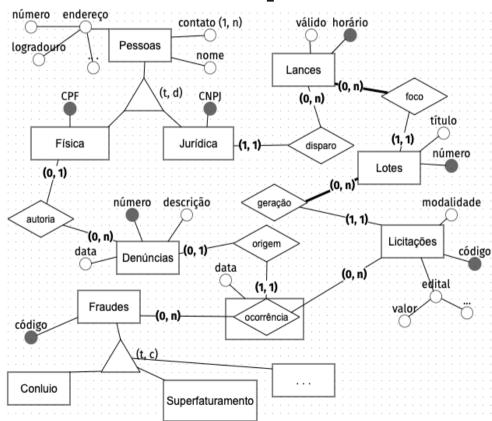
- Qual a diferença entre a arquitetura de um SGPD e...
- a arquitetura de um Data Lake (DL)? Um DL provê acesso a fontes de dados heterogêneas através de múltiplas interfaces de acesso, mas não permite migração/replicação de dados entre/em diferentes fontes em função da evolução do workload e/ou requisitos

# **Agenda**

- 1. Persistência Poliglota: O que é?!
- 2. SGPD: Arquiteturas de base
- 3. SGPD: Desafios & Oportunidades de Pesquisa

Projeto Poliglota de Dados

Projeto Poliglota de Dados



BD grafo número endereco válido horário contato (1, n) **Projeto Poliglota de Dados** logradouro Pessoas nome como "fatiar" uma modelagem conceitual Lances quando o meu objetivo é persistir dados. (t, d) CNPI (O, n) foco em diversas tecnologias de BD (com título diversos modelos de dados)? (1, 1) Jurídica Física **⊢(1, 1**) disparo número elastic Lotes **BDOR** search . número descrição modalidade autoria Licitações origem (0, 1) 🖊 código data Denúncias data (0, n) (1, 1) Fraudes -(0. n)ocorrência código **BDR** documento Conluio

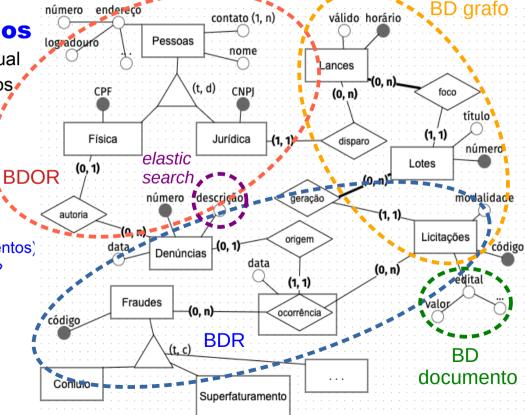
Superfaturamento

### Projeto Poliglota de Dados

 como "fatiar" uma modelagem conceitual quando o meu objetivo é persistir dados em diversas tecnologias de BD (com diversos modelos de dados)?

quais níveis de granularidade vamos permitir o fatiamento? (entidade? entidade + relacion.? grupos de atributos? atributos?...)

 como manter os vínculos (relacionamentos) entre os pedaços? (dados replicados? índices poliglotas (intermodelos)?...)



### Projeto Poliglota de Dados

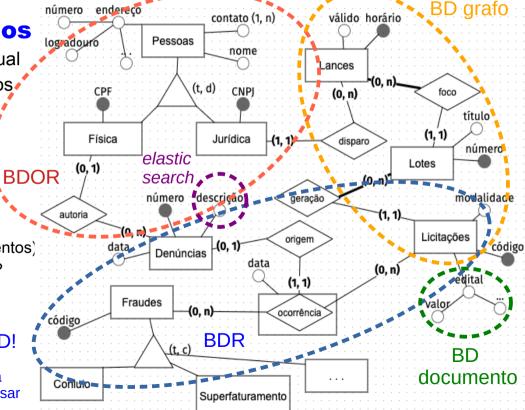
 como "fatiar" uma modelagem conceitual quando o meu objetivo é persistir dados em diversas tecnologias de BD (com diversos modelos de dados)?

quais níveis de granularidade vamos permitir o fatiamento? (entidade? entidade + relacion.? grupos de atributos? atributos?...)

como manter os vínculos (relacionamentos) entre os pedaços? (dados replicados? índices poliglotas (intermodelos)?...),

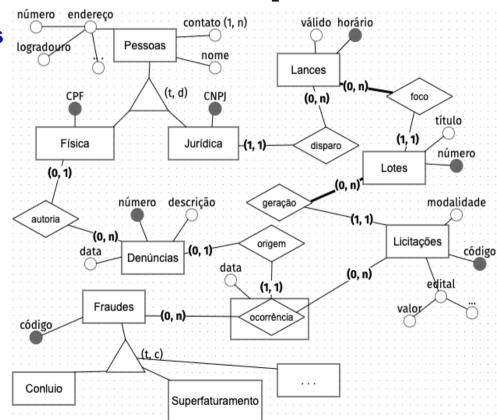
#### valor dos metadados em um SGPD!

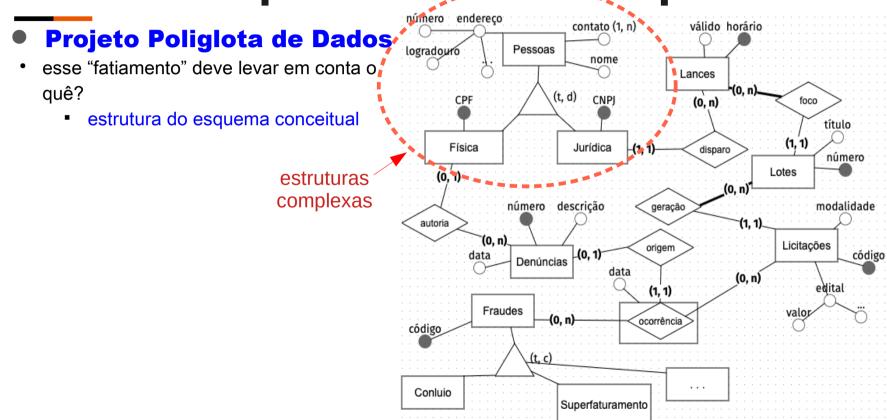
(como estão distribuídos os dados? quais são os mecanismos de acesso? como acessar de forma otimizada uma ou mais tecnologias de BD para processar uma certa operação? ...)

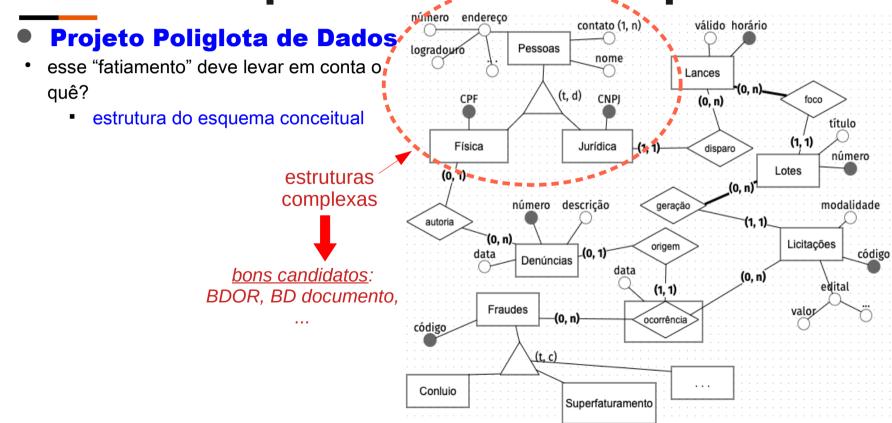


- Projeto Poliglota de Dados
- esse "fatiamento" deve levar em conta o quê?

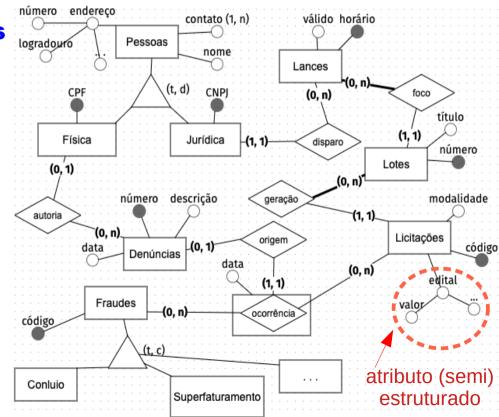
- Projeto Poliglota de Dados
- esse "fatiamento" deve levar em conta o quê?
  - estrutura do esquema conceitual







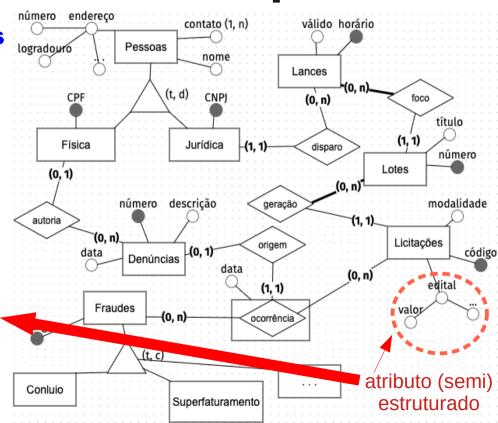
- Projeto Poliglota de Dados
  - esse "fatiamento" deve levar em conta o quê?
    - estrutura do esquema conceitual



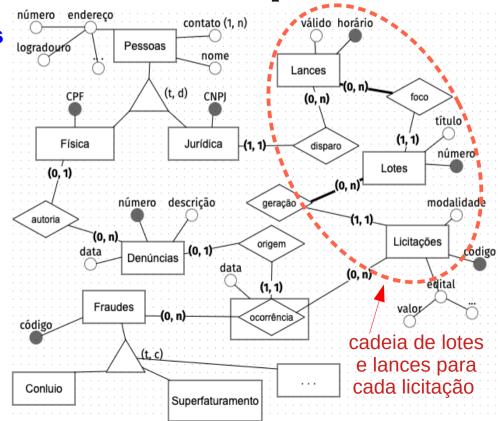
#### Projeto Poliglota de Dados

- esse "fatiamento" deve levar em conta o quê?
  - estrutura do esquema conceitual

bons candidatos:
BDR com campo JSON
ou XML, BD XML, BD
documento, ...

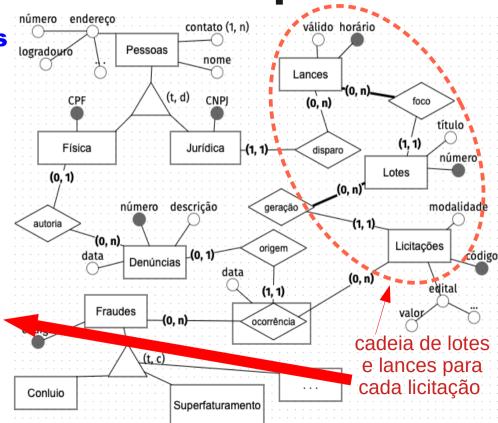


- Projeto Poliglota de Dados
- esse "fatiamento" deve levar em conta o quê?
  - estrutura do esquema conceitual



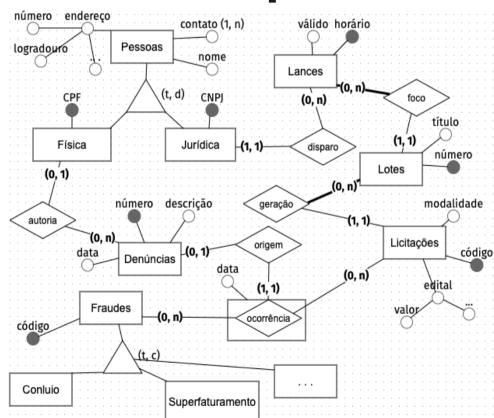
- Projeto Poliglota de Dados
- esse "fatiamento" deve levar em conta o quê?
  - estrutura do esquema conceitual

bons candidatos: BD grafo, BD para blockchain, ...



#### Projeto Poliglota de Dados

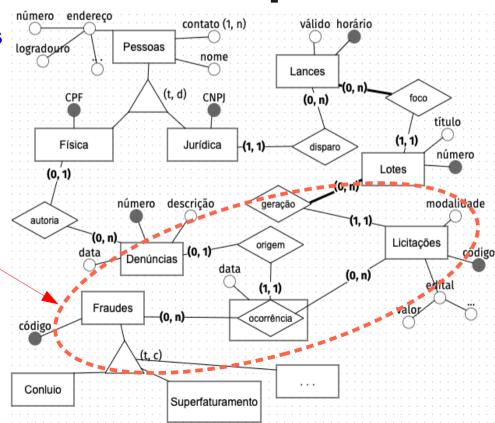
- esse "fatiamento" deve levar em conta o quê?
  - estrutura do esquema conceitual
  - workload estimado



#### Projeto Poliglota de Dados

- esse "fatiamento" deve levar em conta o quê?
  - estrutura do esquema conceitual
  - workload estimado

preciso acessar com frequência fraudes associadas a licitações para descobrir correlações/padrões (p.ex.: certos tipos de fraudes ocorrem muito em certas modalidades de licitação)



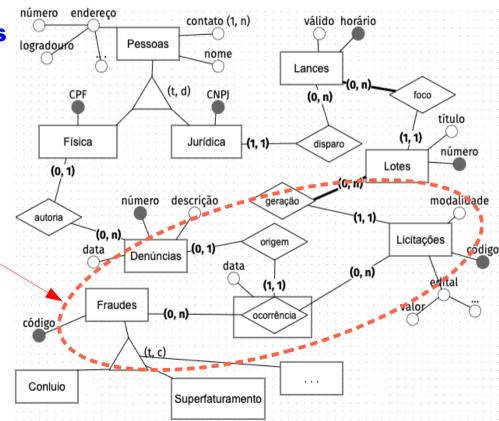
#### Projeto Poliglota de Dados

- esse "fatiamento" deve levar em conta o quê?
  - estrutura do esquema conceitual
  - workload estimado

preciso acessar com frequência fraudes associadas a licitações para descobrir correlações/padrões (p.ex.: certos tipos de fraudes ocorrem muito em certas modalidades de licitação)



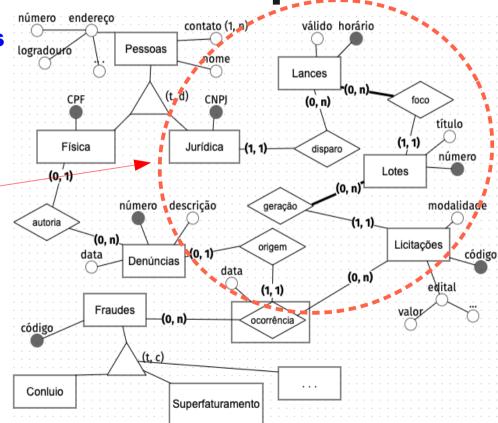
<u>bons candidatos</u>: BDR (efficient joins), DL (analytics), ...



#### Projeto Poliglota de Dados

- esse "fatiamento" deve levar em conta o quê?
  - estrutura do esquema conceitual
  - workload estimado

preciso saber quais empresas têm dado lances em licitações de uma certa modalidade em uma certa região nos últimos anos

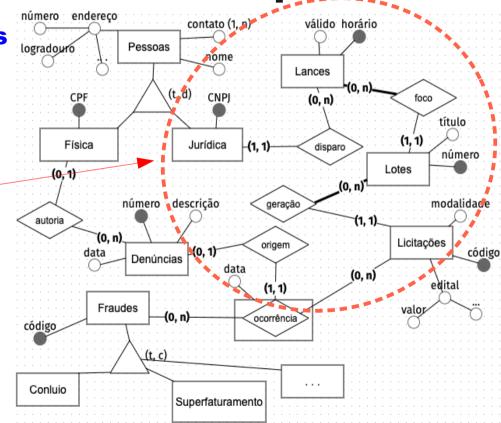


#### Projeto Poliglota de Dados

- esse "fatiamento" deve levar em conta o quê?
  - estrutura do esquema conceitual
  - workload estimado

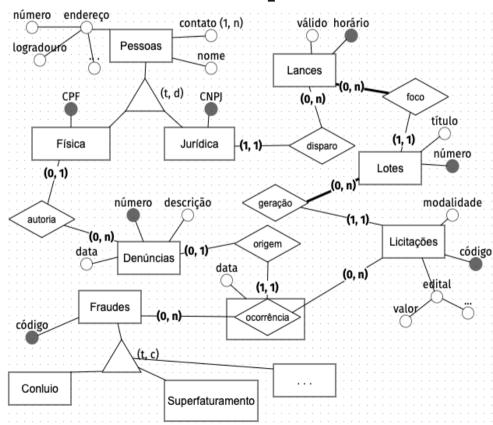
preciso saber quais empresas têm dado lances em licitações de uma certa modalidade em uma certa região nos últimos anos

<u>bons candidatos</u>: BD espaço-temporal, DW, ...



#### Projeto Poliglota de Dados

- esse "fatiamento" deve levar em conta o quê?
  - estrutura do esquema conceitual
  - workload estimado
  - restrições de integridade do domínio (RIs)

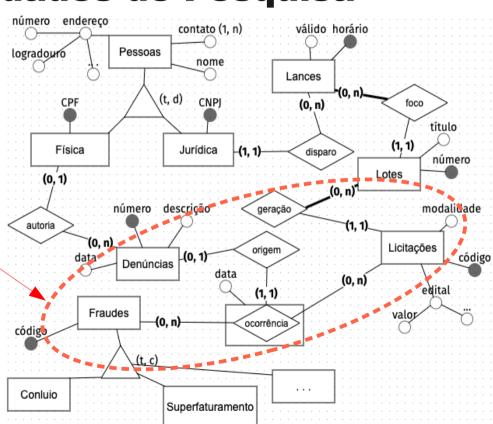


#### Projeto Poliglota de Dados

- esse "fatiamento" deve levar em conta o quê?
  - estrutura do esquema conceitual
  - workload estimado
  - restrições de integridade do domínio (RIs)

certos tipos de fraudes nunca ocorrem em certas modalidades de licitação

 $fraude(tipo = 'X') \Rightarrow \neg(licitação(modalidade = 'Y'))$ 



#### Projeto Poliglota de Dados

- esse "fatiamento" deve levar em conta o quê?
  - estrutura do esquema conceitual
  - workload estimado
  - restrições de integridade do domínio (RIs)

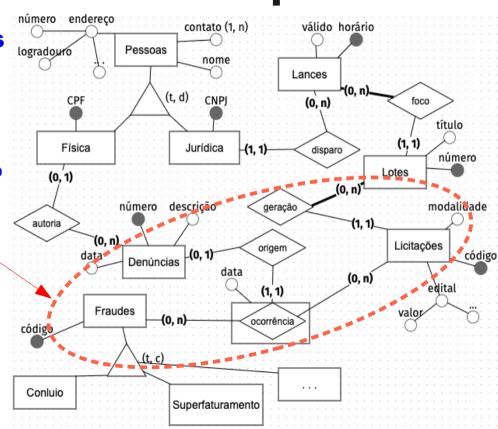
certos tipos de fraudes nunca ocorrem em certas modalidades de licitação

 $fraude(tipo = 'X') \Rightarrow \neg(licitação(modalidade = 'Y'))$ 

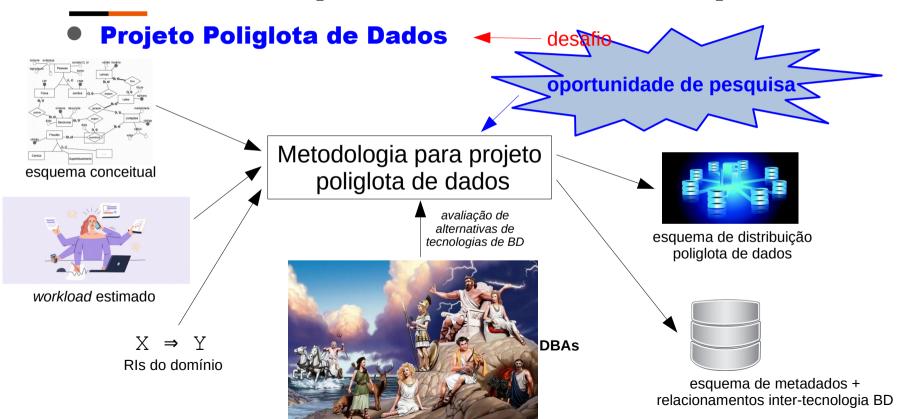


bons candidatos:

BDR (consistência forte, DCL), base de regras de associação ou ontologia, ...



■ Projeto Poliglota de Dados desafio



Interface(s) de acesso para um SGPD

- Interface(s) de acesso para um SGPD
- como definir uma linguagem ou conjunto de métodos de acesso poliglota?



- Interface(s) de acesso para um SGPD
- como definir uma linguagem ou conjunto de métodos de acesso poliglota?
  - uma opção: linguagem universal
    - adotada por alguns SGBDs multimodelo



#### Interface(s) de acesso para um SGPD

- como definir uma linguagem ou conjunto de métodos de acesso poliglota?
  - uma opção: linguagem universal
    - adotada por alguns SGBDs multimodelo
    - <u>exemplo</u>: **AQL** (ArangoDB query language)
      - acesso a um modelo integrado de documentos e grafos, bem como textos longos (search engine)

```
INSERT {
    _key:"GilbertoGil",
    "profession":"singer",
    "age": 80,
    "city": {"name":"Fortaleza", "state":"CE"}
} INTO users
```

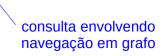


```
FOR x IN 1..2
OUTBOUND 'users/GilbertoGil'
RETURN x.profession;
```





consulta com filtro sobre estrutura complexa de documento FOR u IN users
FOR c IN u.city
FILTER c.state = "CE"
RETURN u.profession

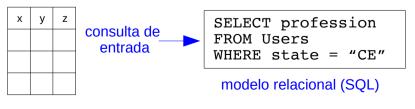


- Interface(s) de acesso para um SGPD
- como definir uma linguagem ou conjunto de métodos de acesso poliglota?
  - outra opção: múltiplas linguagens e tradutores
    - exemplo: protótipo Polypheny DB



```
INSERT INTO Users
(name,profession,age,city,state)
VALUES
("Gilberto Gil","singer", 80,"Fortaleza","CE")
```

CREATE (p:Users{name: "Gilberto
Gil", profession: "singer", age:80,
city: "Fortaleza", state: "CE"});





MATCH (u:Users)
WHERE u.state = "CE"
RETURN u.profession



modelo de grafo (Cypher)

#### Interface(s) de acesso para um SGPD

Abordagem	Prós	Contras
Linguagem universal	interface única de acesso	<ul> <li>expressividade/complexidade para atender diversos modelos de dados</li> <li>mapeamento para vários modelos de dados no caso de uma linguagem abstrata em nível conceitual</li> </ul>
Múltiplas linguagens	maior adaptabilidade à inclusão de novos modelos de dados	<ul> <li>curva de aprendizado de várias linguagens</li> <li>mapeamentos entre linguagens diferentes</li> <li>dificuldade de mapeamento entre linguagens com poder de expressão diferentes</li> </ul>



■ Interface(s) de acesso para um SGPD

oportunidade de pesquisa

Projeto de uma linguagem e/ou métodos de acesso poliglota de BD

■ Interface(s) de acesso para um SGPD

oportunidade de pesquisa

Projeto de uma linguagem e/ou métodos de acesso poliglota de BD

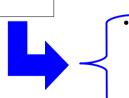
alguns pontos a avaliar...



oportunidade de pesquisa

Projeto de uma linguagem e/ou métodos de acesso poliglota de BD

alguns pontos a avaliar...



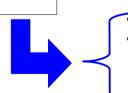
potenciais modelos de dados a suportar

Interface(s) de acesso para um SGPD desafio

oportunidade de pesquisa-

Projeto de uma linguagem e/ou métodos de acesso poliglota de BD

> alguns pontos a avaliar...



potenciais modelos de dados a suportar

estimativa de workload mais estável

■ Interface(s) de acesso para um SGPD

oportunidade de pesquisa

Projeto de uma linguagem e/ou métodos de acesso poliglota de BD

alguns pontos a avaliar...



- potenciais modelos de dados a suportar
- estimativa de workload mais estável
- linguagem(ns) de base a estender (padrões mais consolidados (p.ex.: SQL) facilitam parsing, otimizações, curva de aprendizado, ...)

 Migração de dados entre tecnologias de BD devido à evolução do workload (Evolução do projeto poliglota de dados)



- Migração de dados entre tecnologias de BD devido à evolução do workload
  - como gerenciar isso?



- Migração de dados entre tecnologias de BD devido à evolução do workload
  - como gerenciar isso?
    - manter mapeamentos entre os modelos de dados suportados pelo SGPD?



- Migração de dados entre tecnologias de BD devido à evolução do workload
  - como gerenciar isso?
    - manter mapeamentos entre os modelos de dados suportados pelo SGPD? (desafio: definir regras de mapeamento entre modelos de dados – com completude de conceitos e eficiência de representação)



- Migração de dados entre tecnologias de BD devido à evolução do workload
  - como gerenciar isso?
    - manter mapeamentos entre os modelos de dados suportados pelo SGPD? (desafio: definir regras de mapeamento entre modelos de dados – com completude de conceitos e eficiência de representação)
    - o que fazer no caso de decisão por uma nova tecnologia de BD (novo modelo de dados) para atender melhor esse novo workload? realizar engenharia reversa da porção a ser migrada para um modelo conceitual MC, e a partir do MC realizar o projeto lógico/físico na nova tecnologia?

- Migração de dados entre tecnologias de BD devido à evolução do workload
  - como gerenciar isso?
    - manter mapeamentos entre os modelos de dados suportados pelo SGPD? (desafio: definir regras de mapeamento entre modelos de dados – com completude de conceitos e eficiência de representação)
    - o que fazer no caso de decisão por uma nova tecnologia de BD (novo modelo de dados) para atender melhor esse novo workload? realizar engenharia reversa da porção a ser migrada para um modelo conceitual MC, e a partir do MC realizar o projeto lógico/físico na nova tecnologia?
    - outro desafio: como detectar necessidades de migração de dados? Monitoramento de desempenho de transações OLTP e OLAP?

Migração de dados entre tecnologias de BD devido
 à evolução do workload

## Desafios & Oportunidades de Pesquisa

 Migração de dados entre tecnologias de BD devido à evolução do workload

oportunidade de pesquisa<

Mecanismo de migração de dados em um SGPD

## Desafios & Oportunidades de Pesquisa

Migração de dados entre tecnologias de BD devido

à evolução do workload

oportunidade de pesquisa

Mecanismo de migração de dados em um SGPD

alguns pontos a considerar...

## Desafios & Oportunidades de Pesquisa

 Migração de dados entre tecnologias de BD devido à evolução do workload

oportunidade de pesquisa

Mecanismo de migração de dados em um SGPD



mecanismo mais automatizado possível

## Desafios & Oportunidades de Pesquisa

Migração de dados entre tecnologias de BD devido

à evolução do workload

oportunidade de pesquisa

Mecanismo de migração de dados em um SGPD

alguns pontos a considerar...

- mecanismo mais automatizado possível
- impacto mínimo (ou nulo) nas transações ativas

## Desafios & Oportunidades de Pesquisa

Migração de dados entre tecnologias de BD devido

à evolução do workload

oportunidade de pesquisa-

Mecanismo de migração de dados em um SGPD

alguns pontos a considerar...



- mecanismo mais automatizado possível
- impacto mínimo (ou nulo) nas transações ativas
- monitoramento, detecção e gatilho do processo de migração da forma mais transparente possível para os DBAs (self-managed approach)

#### Referências

- Kiehn, F. et .al. Polyglot Data Management: State of the Art & Open Challenges. PVLDB, 15(12): 3750 – 3753 (2022)
- Roy-Hubara, N.; Shoval, P.; Sturm, A. Selecting Databases for Polyglot Persistence Applications. Data Knowledge Engineering (DKE). 137: 101950 (2022)
- Glake, D. et .al. Towards Polyglot Data Stores Overview and Open Research Questions. CoRR abs/2204.05779 (2022)
- Tan, R. et al. Enabling Query Processing Across Heterogeneous Data Models: A Survey. IEEE BigData, p.3211-3220 (2017)







# Persistência Poliglota:

Fundamentos, Desafios & Oportunidades



**Ronaldo dos Santos Mello** 

r.mello@ufsc.br

GBD/PPGCC/INE/CTC/UFSC

